

Construcción de Imágenes Panorámicas mediante Homografías: Detección de Características, DLT y RANSAC

Vocos Conesa, Tomás
Ing. en Inteligencia Artificial
tvocosconesa@udesa.edu.ar

De Hieronymis, Martín Ariel
Ing. en Inteligencia Artificial
mdhieronymis@udesa.edu.ar

Larisson, Zoe
Ing. en Inteligencia Artificial
zlarisson@udesa.edu.ar

Abstract—Se implementa un pipeline completo de construcción de imágenes panorámicas a partir de conjuntos de tres imágenes con solapamiento parcial. El método detecta características locales mediante SIFT, las redistribuye espacialmente con Supresión de No Máxima Adaptativa (A-NMS), establece correspondencias combinando el test de razón de Lowe con verificación cruzada, estima homografías tanto de forma manual (DLT sobre 4 correspondencias elegidas a mano) como robusta (RANSAC sobre el conjunto completo de correspondencias automáticas), calcula el tamaño óptimo del lienzo final y funde las imágenes proyectadas mediante pesos derivados de la transformada de distancia. Tanto el DLT como RANSAC se implementaron sin recurrir a las rutinas de estimación de OpenCV. El método se evaluó sobre el conjunto provisto *cuadro* y sobre un conjunto propio de tres fotografías del campus de la universidad, obteniendo errores de reproyección finales de entre 1.7 y 2.0 píxeles y panorámicas sin costuras visibles en ambos casos.

I. INTRODUCCIÓN

Una imagen digital es el resultado de proyectar una escena tridimensional sobre un plano a través de un modelo de cámara *pinhole*. Dos fotografías de una misma escena, tomadas con la misma cámara desde distintas posiciones, están relacionadas por una transformación proyectiva lineal de 3×3 (*homografía*, H , con 8 grados de libertad) que mapea puntos homogéneos x de una imagen a puntos x' de la otra,

$$x' \sim Hx, \quad (1)$$

donde $\sim$ denota igualdad a menos de un factor de escala, **si y solo si** se cumple alguna de las siguientes dos hipótesis geométricas:

- 1) La escena observada es (aproximadamente) **plana**, o
- 2) La cámara sufrió únicamente una **rotación pura** alrededor de su centro óptico entre una toma y la otra, sin traslación.

Bajo cualquiera de estas dos hipótesis, la relación entre imágenes no depende de la profundidad de la escena, por lo que una única matriz H alcanza para alinear todos los puntos. Cuando ninguna de las dos se cumple exactamente —es decir, cuando la cámara se traslada y la escena tiene profundidad variable— aparece **paralaje**: objetos a distinta distancia de la cámara se desplazan de forma distinta entre las dos vistas, y ninguna homografía única puede alinearlos

a todos simultáneamente. El síntoma visible es *ghosting* (objetos duplicados o desalineados) en la zona de solapamiento, particularmente en los objetos más cercanos a la cámara.

Análisis de los conjuntos utilizados. El conjunto *cuadro* (Fig. 1) corresponde a un cuadro colgado sobre una pared, fotografiado desde tres posiciones cercanas. La escena es aproximadamente plana —el cuadro domina el campo visual— por lo que la hipótesis (1) se cumple razonablemente bien; el principal apartamiento proviene de que las tomas no son una rotación pura sino que incluyen un leve desplazamiento lateral de la cámara, lo que introduce paralaje respecto del borde de la mesa y de la caja apoyada en primer plano. El conjunto propio (fotos del campus, Fig. 8) es el caso opuesto: la escena *no* es plana (edificio, césped y árboles a distintas profundidades), pero las tres fotos fueron tomadas girando la cámara sobre un mismo punto aproximado, por lo que se aproxima mejor a la hipótesis (2). El paralaje residual se manifiesta principalmente en los árboles del primer plano, que son los objetos más cercanos a la cámara.



Fig. 1. Conjunto *cuadro*: tres tomas con solapamiento parcial de un cuadro colgado sobre una pared. La toma central se usa como ancla.

El resto del informe sigue la numeración de la consigna. La Sección II describe cada etapa del pipeline y los algoritmos implementados; la Sección III reporta los resultados cuantitativos y visuales sobre ambos conjuntos; la Sección IV resume las conclusiones y las limitaciones identificadas. Todo el código se encuentra en `utils.py` y `graficos.py`, orquestado desde el notebook `Tp1_pano.ipynb`.

II. MÉTODO

El pipeline se compone de siete etapas: preprocesamiento, detección y descripción de características, redistribución espacial por A-NMS, asociación de correspondencias, estimación de la homografía (manual por DLT y robusta por RANSAC), cálculo del lienzo óptimo, y *stitching* con *blending*. En todos los casos se toma la imagen central como sistema de referencia (*ancla*) y se estiman dos homografías, $H_{0 \rightarrow 1}$ y $H_{2 \rightarrow 1}$, que llevan las dos imágenes laterales a ese sistema.

A. Preprocesamiento: reescalado de las imágenes

Las imágenes del conjunto *cuadro* tienen una resolución nativa de 3072×4096 píxeles. A esa resolución SIFT detecta del orden de 1.4×10^4 *keypoints* por imagen, en su gran mayoría asociados a detalles de textura muy finos (trazos de pincel, grano de la tela, ruido del sensor). Estos puntos son poco estables entre tomas: pequeños cambios de perspectiva, foco o iluminación alteran su apariencia local y, por lo tanto, su descriptor, lo que se traduce en una alta proporción de correspondencias erróneas.

Por este motivo las tres imágenes se reescalaron por un factor $s = 0.25$ (resolución de trabajo 768×1024) usando `cv2.resize` con interpolación `INTER_AREA`. Esta interpolación promedia sobre el área del píxel de destino, por lo que actúa como un filtro pasa-bajos *antes* del submuestreo, evitando el *aliasing* que produciría un submuestreo directo. El efecto sobre la detección es que SIFT deja de responder al detalle de alta frecuencia y pasa a detectar ≈ 500 *keypoints* por imagen, anclados en estructuras de mayor escala (bordes del cuadro, contornos de las figuras pintadas, esquinas de la mesa), considerablemente más estables frente a cambios de vista. Como se cuantifica en la Sección III, esto reduce la cantidad absoluta de correspondencias pero eleva fuertemente la proporción de *inliers*, además de abaratar el costo de todo el pipeline.

Dos consecuencias de esta decisión merecen explicitarse:

- Las 4 correspondencias del DLT manual (Sección II-E) fueron marcadas sobre las imágenes originales, por lo que se reescalan por el mismo factor s antes de estimar la homografía, de modo que sigan señalando los mismos puntos físicos. Así, cambiar s no obliga a volver a elegirlas a mano.
- El error de reproyección queda expresado en píxeles de la *resolución de trabajo*. Un error de 2 px sobre las imágenes reescaladas equivale a ≈ 8 px en la resolución original, por lo que los errores no son directamente comparables entre conjuntos procesados a distinta escala.

El conjunto propio, en cambio, se procesa a su resolución nativa (1200×1600), que ya es lo bastante moderada como para no requerir reescalado.

B. Detección y descripción de características

Se utilizó el detector-descriptor **SIFT** (*Scale-Invariant Feature Transform*), a través de `cv2.SIFT_create`. SIFT construye un espacio de escalas convolucionando la imagen con Gaussianas de σ creciente y toma diferencias entre escalas

adyacentes (*Difference of Gaussians*); los *keypoints* son los extremos locales de ese volumen en las tres dimensiones (x, y, σ) , lo que les asigna simultáneamente una posición y una escala característica. A cada punto se le asigna luego una orientación dominante a partir de un histograma de gradientes de su vecindad, y el descriptor final es un vector de 128 dimensiones construido como una grilla de 4×4 histogramas de gradientes de 8 orientaciones cada uno, calculados *relativos* a esa orientación dominante y normalizados.

De esta construcción se desprenden sus propiedades de invariancia, que son las que lo hacen apropiado para este problema: invariancia a rotación (por la orientación dominante), a escala (por la detección en el espacio de escalas), y robustez razonable a cambios de iluminación (por la normalización del descriptor) y a cambios de perspectiva moderados. SIFT opera internamente sobre la intensidad, por lo que no fue necesaria una conversión previa a escala de grises.

C. Supresión de No Máxima Adaptativa (A-NMS)

Los *keypoints* de SIFT no se distribuyen de manera uniforme: se concentran en las regiones de mayor textura. Si se usaran todos tal cual, las correspondencias –y por lo tanto la homografía estimada a partir de ellas– quedarían dominadas por esa región, y el ajuste sería pobre en el resto de la imagen. El objetivo de A-NMS es seleccionar un subconjunto de tamaño fijo N que sea a la vez *fuerte* (puntos de alta respuesta) y *espacialmente disperso*.

La idea central es asignar a cada *keypoint* i un **radio de supresión** R_i , definido como la distancia al *keypoint* más cercano que tenga una respuesta estrictamente mayor:

$$R_i = \min_{j: r_j > r_i} \|\mathbf{x}_i - \mathbf{x}_j\|, \quad (2)$$

donde r_i es la respuesta (*response*) del punto i y $\mathbf{x}_i$ su posición. Interpretado geométricamente, R_i es el radio del mayor disco centrado en i dentro del cual i es el punto más fuerte. Un punto aislado en una región poco texturada tiene un R_i grande aunque su respuesta absoluta sea modesta; un punto rodeado de vecinos más fuertes, por bueno que sea, tiene un R_i pequeño. Conservando los N puntos de mayor R_i se obtiene, entonces, una selección que privilegia simultáneamente la calidad local y la cobertura espacial. Al máximo global le corresponde $R_i = \infty$, ya que no existe ningún punto más fuerte que él.

La implementación (`anms` en `utils.py`) es completamente vectorizada: se arma la matriz de distancias cuadradas entre todos los pares de puntos, se enmascara con la condición $r_j > r_i$ reemplazando por ∞ las entradas que no la cumplen, y se toma el mínimo por filas. Como el ordenamiento por R_i y por R_i^2 es el mismo, se trabaja directamente con distancias al cuadrado y se evita la raíz. Respecto de la formulación original de Brown et al., se omite el factor de robustez c_{robust} –que relaja la condición a $r_j > c \cdot r_i$ con $c \approx 0.9$ – y se usa la comparación estricta. Respecto del pseudocódigo del enunciado, no se restringe primero a un conjunto de máximos locales en una vecindad fija: el radio se calcula directamente

sobre la totalidad de los puntos detectados, lo cual da el mismo resultado cualitativo con una implementación más simple.

El costo de esta vectorización es una complejidad de memoria $O(n^2)$ en la cantidad de puntos detectados, lo que obliga a acotar n . Por ese motivo la detección se limita a 16000 *keypoints* por imagen; los valores de $\approx 1.6 \times 10^4$ que se reportan para el conjunto propio corresponden a ese tope y no a una medición del total realmente presente en la imagen.

La Fig. 2 muestra el efecto del método sobre *cuadro_0*, donde los 499 puntos detectados se reducen a $N = 200$. Los grumos más densos sobre las zonas de mayor textura se aligeran y la cobertura sobre la superficie del cuadro queda notablemente más pareja. Conviene notar que la pared y la mesa siguen casi vacías: A-NMS solo puede redistribuir entre los puntos que SIFT detectó, no crear puntos nuevos donde no hay gradiente que detectar. Para el conjunto propio se usó $N = 5000$, acorde a la mayor cantidad de puntos disponibles.




Fig. 2. Conjunto *cuadro* a escala $s = 0.25$. Izquierda: los 499 *keypoints* crudos de SIFT, amontonados sobre las zonas de mayor textura. Derecha: los $N = 200$ seleccionados por A-NMS, con una cobertura más uniforme.

D. Asociación de correspondencias

Dados los descriptores de dos imágenes, se buscan pares de puntos que correspondan al mismo punto físico. La búsqueda de vecinos más cercanos en el espacio de 128 dimensiones se realiza con `cv2.FlannBasedMatcher` (índice KD-tree, 10 árboles, 50 chequeos por consulta), que resuelve el problema de forma *aproximada*: sacrifica la garantía de hallar el vecino exacto a cambio de una búsqueda mucho más rápida, un compromiso razonable dado que los filtros posteriores descartan de todos modos las asociaciones dudosas.

Sobre esa búsqueda se aplican dos criterios de filtrado combinados:

- **Test de razón de Lowe.** Para cada descriptor se recuperan sus dos vecinos más cercanos, a distancias $d_1 \leq d_2$, y el match se acepta solo si

$$d_1 < 0.75 \cdot d_2. \quad (3)$$

La justificación es que un punto que corresponde genuinamente a otro debería estar claramente más cerca

de su verdadero par que de cualquier otro candidato. Cuando $d_1 \approx d_2$ el match es ambiguo –situación típica de las texturas repetitivas, donde varios parches se parecen entre sí– y conviene descartarlo aunque el primer vecino sea efectivamente el correcto, porque no hay forma de distinguirlo del segundo.

- **Verificación cruzada (cross-check).** El matching se corre en ambas direcciones y se conserva un par (i, j) solo si j es el mejor match de i y simultáneamente i es el mejor match de j . Esto elimina las asociaciones asimétricas, en las que un punto que no tiene verdadero par en la otra imagen –por caer fuera de la zona de solapamiento, por ejemplo– se asocia igualmente al descriptor más parecido que logre encontrar.

La combinación de ambos es más estricta que cualquiera por separado: reduce el número final de correspondencias pero eleva fuertemente su confiabilidad, lo que le deja menos trabajo a RANSAC. La Fig. 3 ilustra el resultado para el par *cuadro_0*–*cuadro_1*. Cabe aclarar que esta figura comparativa se generó sobre el conjunto *completo* de descriptores de SIFT, donde el contraste contra el matching sin filtrar se aprecia mejor por haber muchas más correspondencias en juego; el pipeline definitivo aplica exactamente la misma función sobre los descriptores de A-NMS.




Fig. 3. Correspondencias del par *cuadro_0*–*cuadro_1* tras aplicar cross-check y test de Lowe. Las líneas sobrevivientes son marcadamente más paralelas y consistentes entre sí que las del matching sin filtrar.

E. Estimación manual de la homografía (DLT)

Una homografía tiene 8 grados de libertad (9 entradas menos el factor de escala global), y cada correspondencia de puntos aporta 2 ecuaciones independientes, por lo que se necesitan al menos 4 correspondencias no colineales para determinarla. En esta etapa esos 4 pares se eligieron **a mano** sobre las imágenes (Fig. 4), cubriendo distintas zonas del cuadro y evitando que queden alineados: tres puntos casi colineales dejan el sistema mal condicionado y producen una H inestable.

El algoritmo **DLT** (*Direct Linear Transformation*) parte de reescribir (1) de forma que desaparezca el factor de escala

desconocido. Como $\mathbf{x}'$ y $H\mathbf{x}$ son paralelos, su producto vectorial es nulo:

$$\mathbf{x}' \times (H\mathbf{x}) = \mathbf{0}. \quad (4)$$

Desarrollando esta expresión para $\mathbf{x} = (x, y, 1)^\top$ y $\mathbf{x}' = (x', y', 1)^\top$ se obtienen, por cada correspondencia, dos ecuaciones linealmente independientes en las 9 incógnitas $\mathbf{h} = (h_{11}, \dots, h_{33})^\top$, que se apilan en un sistema homogéneo

$$A\mathbf{h} = \mathbf{0}, \quad A \in \mathbb{R}^{2N \times 9}. \quad (5)$$

La solución no trivial que minimiza $\|A\mathbf{h}\|$ sujeta a $\|\mathbf{h}\| = 1$ es el vector singular derecho asociado al menor valor singular de A , que se obtiene de su descomposición en valores singulares (SVD) como la última fila de $V^\top$. Finalmente se fija la escala dividiendo por h_{33} .

Normalización de Hartley. Antes de armar A se normalizan los puntos de cada imagen por separado: se trasladan para que su centroide quede en el origen y se escalan para que su distancia media al origen sea $\sqrt{2}$. Esto es necesario porque las filas de A mezclan términos de orden 1, x y x^2 ; con coordenadas en píxeles del orden de 10^3 , los términos cuadráticos son del orden de 10^6 , el número de condición de A se dispara y la SVD termina amplificando el ruido de localización de los puntos. Si T y T' son las transformaciones de normalización de origen y destino y $\tilde{H}$ la homografía estimada sobre los puntos normalizados, la homografía en coordenadas originales se recupera deshaciendo ambas:

$$H = T'^{-1} \tilde{H} T. \quad (6)$$

La Fig. 5 muestra el resultado de proyectar *cuadro_0* sobre el sistema de *cuadro_1* con la H así obtenida, mezclando ambas al 50% para evaluar visualmente la alineación.



Fig. 4. Las cuatro correspondencias elegidas manualmente entre *cuadro_0* y *cuadro_1*. Cada número y color identifica un par que señala la misma esquina física en ambas tomas.

F. Estimación robusta por RANSAC

El matching automático, aun filtrado con Lowe y cross-check, conserva algunas correspondencias erróneas. El problema es que el ajuste por cuadrados mínimos del DLT no

Resultado del warping (Mezcla 50/50)




Fig. 5. Mezcla 50/50 de *cuadro_1* con *cuadro_0* proyectada mediante la H estimada por DLT manual. La alineación es buena sobre el cuadro, con un leve doble contorno al alejarse de los 4 puntos usados.

es robusto: un solo *outlier* groseramente equivocado puede desviar arbitrariamente la solución, porque el error que aporta entra al costo igual que el de cualquier otra correspondencia. **RANSAC** (*Random Sample Consensus*) resuelve esto invirtiendo la lógica: en lugar de ajustar un modelo a todos los datos y confiar en que los errores se compensen, genera muchos modelos a partir de muestras mínimas y se queda con el que más datos logra explicar.

La implementación (`ransac_homografia`) sigue el Algoritmo 2 del enunciado. En cada una de T iteraciones:

- 1) Se muestrean al azar y sin reposición 4 correspondencias, el mínimo necesario para determinar una homografía.
- 2) Se estima H por DLT sobre esas 4 (si resultan degeneradas –colineales o repetidas– la SVD falla y la iteración se descarta).
- 3) Se proyectan *todas* las correspondencias disponibles con esa H y se cuentan los *inliers*, definidos como aquellos pares cuyo error de reproyección cae por debajo de un umbral t :

$$\|\mathbf{k}_j - H\mathbf{k}_i\| < t. \quad (7)$$

- 4) Se conserva el modelo que haya acumulado el mayor conjunto de *inliers*.

La intuición que sostiene el método es que una muestra contaminada con al menos un *outlier* produce una homografía arbitraria, que ninguna otra correspondencia va a validar; mientras que una muestra de 4 *inliers* produce una homografía cercana a la verdadera, consistente con todas las demás cor-

respondencias correctas. El tamaño del consenso discrimina entonces entre ambas situaciones, sin necesidad de saber de antemano cuáles puntos son buenos.

Terminadas las iteraciones, la homografía final **se recalcula por DLT usando todos los *inliers*** del mejor modelo, no solo las 4 de la muestra ganadora. Este último paso es importante: resolver un sistema sobredeterminado con decenas o cientos de correspondencias correctas promedia el ruido de localización de cada punto y da una estimación sensiblemente más precisa que la que se obtiene del mínimo de 4.

Se usaron $T = 1000$ iteraciones y $t = 5$ píxeles. La elección de T es deliberadamente generosa: la probabilidad de haber extraído al menos una muestra libre de *outliers* es

$$p = 1 - (1 - w^s)^T, \quad (8)$$

con $s = 4$ el tamaño de la muestra y w la fracción de *inliers*. Para el par menos favorable de nuestros datos ($w \approx 0.59$), alcanzar $p = 0.99$ requiere apenas $T \approx 36$ iteraciones; con $T = 1000$ el éxito es prácticamente seguro y el costo sigue siendo despreciable frente al resto del pipeline. La Fig. 6 muestra los *inliers* finales de ambos pares del conjunto *cuadro*: las líneas son casi perfectamente paralelas entre sí, reflejando que todas describen el mismo movimiento aparente entre las tomas.

G. Cálculo del tamaño óptimo del lienzo

Las imágenes laterales, al proyectarse con su homografía, se deforman y pueden caer fuera de los límites de la imagen ancla, incluso en coordenadas negativas. Usar el tamaño del ancla como lienzo recortaría ese contenido; usar un lienzo arbitrariamente grande dejaría bordes negros sobrantes.

La solución implementada calcula el *bounding box* exacto del resultado. Se toman las 4 esquinas de cada imagen lateral, se proyectan al sistema del ancla con su respectiva homografía (`cv2.perspectiveTransform`), y se las une con las 4 esquinas de la propia ancla. De ese conjunto de 12 puntos se extraen $x_{min}, x_{max}, y_{min}, y_{max}$, que determinan el ancho y el alto necesarios. Como x_{min} o y_{min} pueden ser negativos, se construye además una traslación pura

$$T = \begin{pmatrix} 1 & 0 & -x_{min} \\ 0 & 1 & -y_{min} \\ 0 & 0 & 1 \end{pmatrix} \quad (9)$$

que se antepone a cada transformación antes de aplicar `cv2.warpPerspective`: las laterales se proyectan con $T \cdot H_{izq}$ y $T \cdot H_{der}$, y el ancla con T sola. De este modo todo el contenido queda en coordenadas no negativas y el lienzo tiene exactamente el tamaño necesario. Para el conjunto *cuadro* el resultado fue un lienzo de 1496×1658 px con una traslación de (410, 202) px.

H. Stitching y blending

Proyectadas las tres imágenes sobre el lienzo común, resta combinarlas. Pegarlas una sobre otra dejaría una costura dura y visible en las zonas de solapamiento, porque las tomas difieren en exposición, balance de blancos y viñeteo.




Fig. 6. Correspondencias clasificadas como *inlier* por RANSAC, las únicas usadas para calcular la H final. Arriba: *cuadro_0-cuadro_1*. Abajo: *cuadro_2-cuadro_1*.

Para evitarlo se implementó un *blending* ponderado por la **transformada de distancia**. Para cada imagen proyectada se construye una máscara binaria de contenido no negro y se le aplica `cv2.distanceTransform`, que asigna a cada píxel su distancia al borde más cercano de esa máscara. El resultado es un mapa de pesos W_k que vale casi cero en los bordes de la imagen proyectada y crece hacia su interior. El color final de cada píxel del lienzo se obtiene como el promedio ponderado

$$I = \frac{\sum_k W_k I_k}{\sum_k W_k}, \quad (10)$$

aplicado de forma independiente e idéntica a los tres canales de color (los pesos no dependen del color, por lo que promediar canal por canal es equivalente a hacerlo vectorialmente).

El criterio tiene una lectura natural: en la zona de solapamiento, la imagen que más aporta a un píxel es aquella para la cual ese píxel está más lejos de su propio borde, es decir, la que lo observa más de lleno y no al filo de su campo visual. Como los pesos varían de forma continua, la transición de una imagen a la siguiente es gradual y la costura desaparece.

TABLE I

MATCHES, INLIERS Y ERROR DE REPROYECCIÓN POR PAR DE IMÁGENES. LOS PARES *cuadro* SE PROCESARON A 768×1024 (ESCALA $s = 0.25$, $N = 200$) Y LOS *propio* A SU RESOLUCIÓN NATIVA 1200×1600 ($N = 5000$); EL ERROR ESTÁ EXPRESADO EN PÍXELES DE LA RESOLUCIÓN DE TRABAJO DE CADA CONJUNTO (VER SECCIÓN II-A).

Par	Matches	Inliers	% Inliers	Error (px)
cuadro 0-1	33	23	70%	2.01
cuadro 2-1	22	13	59%	1.69
propio 0-1	600	375	63%	1.97
propio 2-1	447	281	63%	1.80

III. RESULTADOS

La Tabla I resume los resultados cuantitativos, obtenidos con $T = 1000$ iteraciones y umbral $t = 5$ px. El error de reproyección promedio sobre los *inliers* finales se mantiene entre 1.7 y 2.0 px en los cuatro pares, valores del orden de la precisión de localización del propio detector, lo que indica que las homografías ajustan bien a las correspondencias que las sustentan.

Efecto del reescalado. Los valores del conjunto *cuadro* reflejan la decisión discutida en la Sección II-A. En una corrida preliminar a resolución completa, el par *cuadro_0-cuadro_1* registraba 145 correspondencias iniciales pero apenas un 46% de *inliers*, y el par *cuadro_2-cuadro_1* un 16% (9 de 56), un régimen en el que la homografía se apoyaba en muy pocos puntos y resultaba sensible a la muestra particular que RANSAC encontrara. Trabajando sobre las imágenes reescaladas, la cantidad absoluta de correspondencias baja –hay bastantes menos *keypoints* disponibles– pero la fracción que RANSAC valida como consistente con una única homografía sube a 70% y 59% respectivamente. Es decir: el reescalado no mejora el pipeline por producir *más* correspondencias, sino por producir correspondencias *mejores*. Al suprimir el detalle de alta frecuencia sobre el que SIFT anclaba puntos poco repetibles, las que sobreviven al matching describen estructuras que efectivamente se corresponden entre tomas.

Comparación entre conjuntos. El conjunto propio, con mucha más textura y contraste (fachada del edificio, ventanas, árboles) que el fondo liso de pared y mesa del conjunto *cuadro*, produjo un orden de magnitud más de correspondencias en términos absolutos: 600 y 447, contra 33 y 22. La *proporción* de *inliers*, en cambio, se mantiene en valores comparables a los del otro conjunto ($\approx 63\%$). Lo que aporta robustez en el conjunto propio, entonces, no es un porcentaje más alto sino la cantidad absoluta de *inliers* con la que se recalcula la homografía final por cuadrados mínimos: varios cientos de ecuaciones en lugar de una decena, lo que promedia mucho mejor el error de localización de cada punto individual.

Las Fig. 7 y 8 muestran los resultados finales. En ambos casos el lienzo tiene el tamaño exacto –sin bordes negros sobrantes ni recorte de contenido– y la transición entre imágenes es suave, sin costuras apreciables a simple vista. En el conjunto *cuadro* la superficie del cuadro se lee como una sola pieza continua a lo largo de toda la panorámica. En el conjunto propio se observa un leve *ghosting* en los árboles más cercanos




Fig. 7. Panorámica final del conjunto *cuadro*, con blending por transformada de distancia.



Fig. 8. Panorámica final del conjunto propio (campus de la universidad). El leve *ghosting* en los árboles del primer plano es consistente con el paralaje residual discutido en la Sección I.

a la cámara, exactamente donde el análisis geométrico de la Sección I anticipaba que aparecería: son los objetos de menor profundidad y, por lo tanto, los más sensibles a que la rotación de la cámara no haya sido perfectamente pura.

IV. CONCLUSIONES

Se implementó un pipeline completo de *stitching* panorámico –detección SIFT, redistribución por A-NMS, matching con cross-check y test de Lowe, DLT manual, RANSAC, cálculo de lienzo óptimo y blending por transformada de distancia–, con el DLT y RANSAC escritos

desde cero sin recurrir a las rutinas de estimación de OpenCV. El pipeline se validó sobre el conjunto provisto y sobre uno propio, obteniendo en ambos errores de reproyección finales de entre 1.7 y 2.0 px y panorámicas visualmente libres de costuras.

El hallazgo metodológico más relevante del trabajo fue el impacto del reescalado de las imágenes de entrada. Reducir la resolución a un cuarto antes de detectar características, lejos de degradar el resultado, elevó la proporción de *inliers* del 46% y 16% al 70% y 59% en los dos pares del conjunto *cuadro*. La explicación es que el filtrado pasa-bajos implícito en el submuestreo elimina el detalle de alta frecuencia sobre el cual SIFT ancla puntos poco repetibles entre tomas. Esto sugiere que, para escenas con textura fina, la resolución de trabajo es un hiperparámetro tan relevante como los umbrales del propio matching.

Entre las limitaciones identificadas, la implementación vectorizada de A-NMS tiene complejidad de memoria $O(n^2)$ en la cantidad de *keypoints*, lo que obliga a acotar la detección y sería el primer punto a optimizar –por ejemplo, mediante una estructura espacial que evite calcular todas las distancias por pares–. El umbral de *inlier* t está expresado en píxeles de la resolución de trabajo, por lo que no es directamente transferible entre conjuntos procesados a distinta escala. La cantidad de iteraciones de RANSAC está fijada en $T = 1000$ en lugar de adaptarse dinámicamente a la proporción de *inliers* estimada sobre la marcha, lo cual, según (8), permitiría terminar en unas pocas decenas de iteraciones sin pérdida de garantías. Finalmente, el módulo de blending está escrito específicamente para tres imágenes en disposición izquierda–centro–derecha; generalizarlo a N imágenes arbitrarias requeriría reemplazar el encadenamiento fijo de homografías por un grafo de conexiones entre vistas.