

Construcción de Imágenes Panorámicas mediante Homografías: Detección de Características, DLT y RANSAC

Vocos Conesa, Tomás
Ingeniería en Inteligencia Artificial
Universidad de San Andrés
Buenos Aires, Argentina
tvocosconesa@udesa.edu.ar

De Hieronymis, Martín Ariel
Ingeniería en Inteligencia Artificial
Universidad de San Andrés
Buenos Aires, Argentina
mdehieronymis@udesa.edu.ar

Larisson, Zoe
Ingeniería en Inteligencia Artificial
Universidad de San Andrés
Buenos Aires, Argentina
zlarisson@udesa.edu.ar

Abstract—Se implementa un pipeline completo de construcción de imágenes panorámicas a partir de conjuntos de tres imágenes con solapamiento parcial. El método detecta características locales mediante SIFT, las redistribuye espacialmente con Supresión de No Máxima Adaptativa (A-NMS), establece correspondencias con verificación cruzada y el test de razón de Lowe, estima homografías tanto de forma manual (DLT sobre 4 correspondencias) como robusta (RANSAC), calcula el tamaño óptimo del lienzo final y funde las imágenes proyectadas mediante una máscara de distancia. El método se evaluó sobre el conjunto provisto *cuadro* y sobre un conjunto propio de tres fotografías del campus de la universidad.

I. INTRODUCCIÓN

Una imagen digital es el resultado de proyectar una escena tridimensional sobre un plano a través de un modelo de cámara *pinhole*. Dos fotografías de una misma escena, tomadas con la misma cámara desde distintas posiciones, están relacionadas por una transformación proyectiva lineal de 3×3 (*homografía*, H , con 8 grados de libertad) que mapea puntos homogéneos x de una imagen a puntos x' de la otra ($x' \sim Hx$) si y solo si se cumple alguna de las siguientes dos hipótesis geométricas:

- 1) La escena observada es (aproximadamente) **plana**, o
- 2) La cámara sufrió únicamente una **rotación pura** alrededor de su centro óptico entre una toma y la otra, sin traslación.

Bajo cualquiera de estas dos hipótesis, la relación entre imágenes no depende de la profundidad de la escena, por lo que una única matriz H alcanza para alinear todos los puntos. Cuando ninguna de las dos hipótesis se cumple exactamente —es decir, cuando la cámara se traslada y la escena tiene profundidad variable— aparece **paralaje**: objetos a distinta distancia de la cámara se desplazan de forma distinta entre las dos vistas, y ninguna homografía única puede alinearlos a todos simultáneamente. El síntoma visible de esto es *ghosting* (objetos duplicados o desalineados) en la zona de solapamiento, particularmente en los objetos más cercanos a la cámara.

Análisis de los conjuntos utilizados: El conjunto *cuadro* (Fig. 1) corresponde a un cuadro apoyado sobre una mesa,

fotografiado desde tres posiciones cercanas. La escena es aproximadamente plana (el cuadro domina el campo visual), por lo que la hipótesis (1) se cumple razonablemente bien; el principal apartamiento proviene de que las tomas no son una rotación pura sino que incluyen un leve desplazamiento lateral de la cámara sobre la mesa, lo que introduce paralaje leve respecto del borde de la mesa y del piso, visibles como fondo no plano. El conjunto propio (fotos del campus, Fig. 8) es lo opuesto: la escena *no* es plana (edificio, césped y árboles a distintas profundidades), pero las tres fotos fueron tomadas girando la cámara sobre un mismo punto aproximado, por lo que se aproxima mejor a la hipótesis (2). El paralaje residual se manifiesta principalmente en los árboles del primer plano, que son los objetos más cercanos a la cámara.



Fig. 1. Conjunto *cuadro*: tres tomas con solapamiento del 30–40% de un cuadro sobre una mesa.

II. MÉTODO

El pipeline implementado sigue el esquema general del enunciado: detección y descripción de características, A-NMS, matching, estimación de homografía (manual y por RANSAC), cálculo del lienzo óptimo, y stitching con blending. Todo el código se encuentra en `tpl_panoramica/utils.py` y `tpl_panoramica/graficos.py`, orquestado desde `Tpl_pano.ipynb`.

A. Preprocesamiento: reescalado de las imágenes

Las imágenes del conjunto *cuadro* tienen una resolución nativa de 3072×4096 píxeles. A esa resolución SIFT detecta

del orden de 1.4×10^4 *keypoints* por imagen, en su gran mayoría asociados a detalles de textura muy finos del propio cuadro (trazos de pincel, grano de la tela). Estos puntos son poco estables entre tomas: pequeños cambios de perspectiva o de foco alteran su apariencia local y, por lo tanto, su descriptor, lo que se traduce en un alto porcentaje de correspondencias erróneas.

Por este motivo las tres imágenes se reescalaron por un factor $s = 0.25$ (resolución de trabajo 768×1024) con `cv2.resize` e interpolación `INTER_AREA`, que promedia sobre el área del píxel de destino y actúa por lo tanto como un filtro pasa-bajos antes del submuestreo. El efecto es que SIFT deja de responder al detalle de alta frecuencia y detecta un número mucho menor de *keypoints* (≈ 500 por imagen), asociados a estructuras de mayor escala (bordes del cuadro, contornos de las figuras, esquinas de la mesa), que son considerablemente más estables frente a los cambios de vista. Como se discute en la Sección III, esto reduce la cantidad absoluta de correspondencias pero eleva fuertemente la proporción de *inliers*, además de abaratar el costo computacional de todo el pipeline.

Dos consecuencias de esta decisión merecen explicitarse. Primero, las 4 correspondencias del DLT manual fueron seleccionadas sobre las imágenes originales, por lo que se reescalan por el mismo factor s antes de estimar la homografía, de modo que sigan señalando los mismos puntos físicos. Segundo, el error de reproyección queda expresado en píxeles de la *resolución de trabajo*: un error de 2 px sobre las imágenes reescaladas equivale a ≈ 8 px en la resolución original, por lo que los errores no son directamente comparables entre conjuntos procesados a distinta escala.

El conjunto propio, en cambio, se procesa a su resolución nativa (1200×1600), que ya es suficientemente moderada como para no requerir reescalado.

B. Detección y descripción de características

Se utilizó el detector-descriptor **SIFT** (`cv2.SIFT_create`), por su invariancia a escala, rotación e iluminación y su buen desempeño frente a los cambios de perspectiva presentes en ambos conjuntos. SIFT opera internamente en escala de grises, por lo que no fue necesaria una conversión previa.

C. Supresión de No Máxima Adaptativa (A-NMS)

Para evitar que las correspondencias se concentren en regiones muy texturadas de la imagen (p.ej. el propio cuadro) en desmedro del resto, se implementó A-NMS: para cada *keypoint* k_i se calcula el radio de supresión R_i como la menor distancia a otro *keypoint* k_j con respuesta estrictamente mayor ($r_j > r_i$), y se conservan los N puntos con mayor R_i . A diferencia del pseudocódigo del enunciado, no se restringe primero a un conjunto de máximos locales en una vecindad fija: el radio robusto se calcula directamente sobre la totalidad de los *keypoints* detectados. Esta variante (equivalente a la formulación original de Brown et al.) da el mismo resultado

cualitativo –puntos mejor distribuidos espacialmente– con una implementación vectorizada más simple.

Cabe notar que A-NMS solo actúa efectivamente cuando la cantidad de *keypoints* detectados supera el tope N solicitado. Tras el reescalado de la Sección II-A, SIFT detecta 499, 433 y 504 puntos en las tres imágenes del conjunto *cuadro*, valores por debajo del $N = 2000$ configurado, por lo que para este conjunto A-NMS se comporta como una identidad: el reescalado ya cumplió, por la vía del filtrado pasa-bajos, buena parte del rol de descarte que en el pipeline original recaía sobre A-NMS. El efecto del método sí es apreciable en el conjunto propio, donde se detectan $\approx 1.6 \times 10^4$ *keypoints* por imagen y A-NMS los reduce a los $N = 5000$ mejor distribuidos. La Fig. 2 ilustra el caso del conjunto *cuadro*.




Fig. 2. Conjunto *cuadro* a escala $s = 0.25$. Izquierda: *keypoints* crudos de SIFT (499). Derecha: salida de A-NMS. Al ser 499 menor que el tope $N = 2000$, no se descarta ningún punto y ambos paneles coinciden.

D. Asociación de correspondencias (matching)

Se combinaron dos criterios de filtrado, aplicados en ambas direcciones (imagen $1 \rightarrow 2$ y $2 \rightarrow 1$) usando `cv2.FlannBasedMatcher` con $k = 2$ vecinos:

- **Test de razón de Lowe:** se descarta un match si la distancia al primer vecino no es al menos 30% menor que la distancia al segundo (umbral 0.75).
- **Verificación cruzada (cross-check):** se conserva un match solo si es mutuamente el mejor en ambas direcciones.

La combinación de ambos criterios es más estricta que cualquiera por separado, lo que reduce el número final de correspondencias pero aumenta fuertemente su confiabilidad antes incluso de aplicar RANSAC (ver Sección III). La Fig. 3 muestra el resultado para el par *cuadro_0-cuadro_1*.

E. Estimación manual de la homografía (DLT)

Para uno de los pares del conjunto *cuadro* se seleccionaron manualmente 4 correspondencias (Fig. 4), eligiendo puntos bien distribuidos espacialmente y **no colineales** (tres puntos colineales, o casi, degeneran el sistema lineal y producen una



Fig. 3. Correspondencias tras cross-check + test de Lowe, cuadro_0 - cuadro_1.

H inestable o indeterminada). A partir de estos 4 pares se resolvió el algoritmo **DLT** (*Direct Linear Transformation*) sin usar OpenCV: cada correspondencia $(x, y) \leftrightarrow (x', y')$ aporta dos filas a una matriz $A \in \mathbb{R}^{2N \times 9}$ a partir de $\mathbf{x}' \times (H\mathbf{x}) = 0$, y H se obtiene como el vector singular derecho asociado al menor valor singular de A (SVD). Previamente se normalizan los puntos (normalización de Hartley: centrar en el origen y escalar para que la distancia media al origen sea $\sqrt{2}$) para mejorar el condicionamiento numérico del sistema. La Fig. 5 muestra el resultado de proyectar *cuadro_0* sobre *cuadro_1* con la H obtenida.



Fig. 4. Cuatro correspondencias elegidas manualmente entre cuadro_0 y cuadro_1.

F. RANSAC para eliminación de outliers

Dado que el matching automático produce correspondencias erróneas (*outliers*), se implementó **RANSAC** sin OpenCV siguiendo el Algoritmo 2 del enunciado: en cada una de $T = 1000$ iteraciones se muestrean 4 correspondencias al azar, se calcula H con DLT, y se cuentan los *inliers* –pares cuya

Resultado del warping (Mezcla 50/50)




Fig. 5. Mezcla 50/50 de cuadro_1 con cuadro_0 proyectada mediante la H estimada por DLT manual.

distancia de reproyección $\|k_j - H \cdot k_i\|$ es menor a un umbral $t = 5$ píxeles–. Se conserva el modelo con más *inliers* a lo largo de las iteraciones, y la homografía final se recalcula por DLT usando *únicamente* el conjunto de *inliers* del mejor modelo (mínimos cuadrados sobreajustado, más estable que los 4 puntos mínimos). La Fig. 6 muestra los *inliers* finales para ambos pares del conjunto *cuadro*.

G. Cálculo del tamaño óptimo del lienzo

Para que la imagen final no tenga bordes negros innecesarios ni recorte contenido, se proyectan las 4 esquinas de cada imagen lateral al sistema de referencia de la imagen ancla usando su homografía (H_{izq} , H_{der} , con `cv2.perspectiveTransform`), y se agrupan junto con las esquinas de la propia imagen ancla. Tomando el mínimo y máximo de las coordenadas x e y de ese conjunto se obtiene el *bounding box* que contiene a las tres imágenes ya proyectadas. El ancho y alto del lienzo final son, respectivamente, $x_{max} - x_{min}$ y $y_{max} - y_{min}$, y se construye una matriz de traslación pura

$$T = \begin{pmatrix} 1 & 0 & -x_{min} \\ 0 & 1 & -y_{min} \\ 0 & 0 & 1 \end{pmatrix}$$

que se antepone a cada homografía ($T \cdot H_{izq}$, T , $T \cdot H_{der}$ para la imagen ancla) antes de aplicar `cv2.warpPerspective`, de modo que todo el contenido proyectado caiga dentro de




Fig. 6. Correspondencias *inlier* tras RANSAC. Arriba: cuadro_0–cuadro_1. Abajo: cuadro_2–cuadro_1.

coordenadas no negativas y el lienzo tenga exactamente el tamaño necesario.

H. *Stitching y blending*

Cada imagen se proyecta sobre el lienzo común con `cv2.warpPerspective`. Para evitar costuras visibles se calcula, por imagen, un mapa de pesos W_i mediante `cv2.distanceTransform` sobre la máscara binaria de contenido no negro: los píxeles más alejados del borde de la imagen (y por lo tanto más confiables) reciben mayor peso. El píxel final en cada canal de color se obtiene como el promedio ponderado

$$I = \frac{\sum_i W_i \cdot I_i}{\sum_i W_i},$$

aplicado de forma independiente e idéntica a los tres canales RGB (los pesos W_i no dependen del color, por lo que el resultado es equivalente a promediar canal por canal).

III. RESULTADOS

La Tabla I resume los resultados cuantitativos ($T = 1000$, $t = 5$ px). En ambos pares del conjunto *cuadro* la proporción de *inliers* es alta (76% y 67%) y el error de reproyección

TABLE I

MATCHES, INLIERS Y ERROR DE REPROYECCIÓN POR PAR DE IMÁGENES. LOS PARES *cuadro* SE PROCESARON A 768×1024 (ESCALA $s = 0.25$) Y LOS *propio* A SU RESOLUCIÓN NATIVA 1200×1600 ; EL ERROR ESTÁ EXPRESADO EN PÍXELES DE LA RESOLUCIÓN DE TRABAJO DE CADA CONJUNTO (VER SECCIÓN II-A).

Par	Matches	Inliers	% Inliers	Error (px)
cuadro 0–1	71	54	76%	1.69
cuadro 2–1	36	24	67%	2.07
propio 0–1	600	387	65%	1.95
propio 2–1	445	275	62%	1.89

promedio sobre los *inliers* finales es de aproximadamente 2 px, lo que indica una H bien ajustada a las correspondencias que la sustentan.

Estos valores reflejan el efecto del reescalado descrito en la Sección II-A. En una corrida preliminar a resolución completa, el par *cuadro_0*–*cuadro_1* registraba 145 correspondencias iniciales pero solo un 46% de *inliers*, y el par *cuadro_2*–*cuadro_1* apenas un 16% (9 de 56). Al trabajar sobre las imágenes reescaladas, la cantidad absoluta de correspondencias baja aproximadamente a la mitad –hay muchos menos *keypoints* disponibles– pero la fracción que RANSAC valida como consistente con una única homografía sube en ambos pares por encima del 65%. Es decir, el reescalado no mejora el pipeline por producir *más* correspondencias sino por producir correspondencias *mejores*: al suprimir el detalle de alta frecuencia sobre el que SIFT anclaba puntos inestables, las que sobreviven al matching describen estructuras que efectivamente se corresponden entre tomas.

El conjunto *propio*, con mayor cantidad absoluta de textura visual (fachada del edificio, ventanas, árboles), produjo muchas más correspondencias en términos absolutos (600 y 445) y una proporción de *inliers* alta y estable en ambos pares (65% y 62%), consistente con el análisis de la Sección I: al aproximarse mejor a una rotación pura de cámara, el modelo de homografía es más preciso en más regiones de la imagen.

Las Fig. 7 y 8 muestran los resultados finales. En ambos casos el lienzo tiene el tamaño óptimo (sin bordes negros sobrantes ni recorte de contenido) y la transición entre imágenes es suave gracias al *blending* por distancia. En el conjunto *propio* se observa un leve *ghosting* en los árboles más cercanos a la cámara, consistente con el paralaje residual discutido en la introducción.

IV. CONCLUSIONES

Se implementó un pipeline completo de *stitching* panorámico –detección SIFT, A-NMS, matching con cross-check y test de Lowe, DLT manual, RANSAC, cálculo de lienzo óptimo y *blending* por distancia– validado sobre un conjunto provisto y uno *propio*, con errores de reproyección finales de pocos píxeles. Como trabajo futuro, el número de iteraciones de RANSAC podría adaptarse dinámicamente según la proporción estimada de *inliers* en lugar de fijarse en $T = 1000$, y el pipeline de *blending* –actualmente escrito

específicamente para 3 imágenes (izquierda-centro-derecha)–
podría generalizarse a N imágenes arbitrarias.




Fig. 7. Panorámica final del conjunto *cuadro*, con blending por transformada de distancia.



Fig. 8. Panorámica final del conjunto propio (campus de la universidad).